

MCDI504

MACHINE LEARNING I

INFORME FINAL DEL PROYECTO — FASE 4
EVALUACIÓN Y VALIDACIÓN DEL MODELO

Nombre integrante/s:

Pablo Rodríguez,

Luiskar Espinoza

Henry Moraga

Evaluación: Semana 04. Sumativa 3: Informe final del proyecto Fase 4

Curso: MCDI504 - Machine Learning I

Docente: David Ruete Zúñiga

Fecha: 04 de septiembre de 2026

Grupo: 6

Link: https://github.com/LUISKARESPINOZA/MCDI504_S4_GRUPO6

APARTADOS

- I. Portada e índice
- II. Evaluación del desempeño del modelo
- III. Reporte tabulado e interpretación de métricas del modelo
- IV. Matriz de confusión y métricas de clasificación
- V. Interpretación del desempeño del modelo
- VI. Interpretación para toma de decisiones
- VII. Notebook y trazabilidad del proceso de evaluación del modelo
- VIII. Conclusiones técnicas del desempeño del modelo
- IX. Reporte tabulado e interpretación de estabilidad de métricas
- X. Justificación de técnica de validación
- XI. Coherencia metodológica de validación
- XII. Notebook y trazabilidad del proceso de validación
- XIII. Conclusiones técnicas del proceso de validación
- XIV. Uso de fuentes, citación y referencias
- XV. Anexos

II. Evaluación del desempeño del modelo

El objetivo de la Fase 4 es evaluar y validar el clasificador desarrollado para el caso ABP, transformando las predicciones en evidencia cuantitativa sobre aciertos, errores y capacidad de generalización. La evaluación se construye desde el notebook MCDI504_S4_2_GRUPO6.ipynb y mantiene como problema analítico la predicción de supervivencia de pasajeros del Titanic. La variable objetivo es survived y la clase positiva utilizada para precision, recall y F1-score es sobrevivió (1).

El notebook carga desde OpenML la versión 1 del dataset Titanic mediante fetch_openml. La ejecución registrada contiene 1.309 observaciones y 14 columnas. La distribución de la variable objetivo es 809 pasajeros no sobrevivientes (61,80 %) y 500 sobrevivientes (38,20 %). La diferencia entre clases no es extrema, pero justifica interpretar accuracy junto con métricas específicas de la clase positiva, tal como recomienda el material docente (Ruete, 2026a).

Elemento	Descripción verificada en el notebook
Dataset	Titanic - OpenML, versión 1
Dimensión inicial	1.309 registros x 14 columnas
Variable objetivo	survived: 0 = no sobrevivió; 1 = sobrevivió
Clase objetivo	Sobrevivió (1)
Predictores iniciales	pclass, sex, age, sibsp, parch, fare, embarked
Predictores tras codificación	pclass, age, sibsp, parch, fare, sex_male, embarked_Q, embarked_S
Entrenamiento	1.047 observaciones (80 %)
Prueba	262 observaciones (20 %)
Modelos evaluados	Regresión Logística, Random Forest y Red Neuronal MLP
Modelo final	MLP con una capa oculta de 16 neuronas




Figura 1. Distribución de la variable objetivo survived en el dataset utilizado por el notebook.

Pipeline analítico verificado

El flujo implementado sigue la secuencia: carga y exploración del dataset; exclusión de variables de alta cardinalidad o con riesgo de fuga de información; partición estratificada 80/20; imputación calculada únicamente con el conjunto de entrenamiento; codificación de variables categóricas; escalamiento de variables numéricas; entrenamiento de tres clasificadores; evaluación Hold-Out en el mismo conjunto de prueba; validación cruzada estratificada de la Red Neuronal; y selección del modelo final. Esta lógica es consistente con la orientación de la Fase 4 de preparar, particionar, ajustar, predecir, medir y comparar (Universidad Andrés Bello, 2026).

Nota metodológica: La partición se realiza antes de imputar, codificar y escalar. Para el conjunto de prueba, los parámetros de imputación y escalamiento se aprenden solo desde entrenamiento, por lo que la evaluación Hold-Out permanece independiente del test.

III. Reporte tabulado e interpretación de métricas del modelo

La rúbrica exige reportar accuracy, precision, recall y F1-score e interpretar su relación con el desempeño. Se incorpora además ROC-AUC como métrica complementaria porque el Resultado de Aprendizaje RA4 la incluye explícitamente. Accuracy resume los aciertos globales; precision mide la confiabilidad de las predicciones positivas; recall indica qué proporción de sobrevivientes reales fue detectada; y F1-score equilibra precision y recall (Ruete, 2026a). ROC-AUC resume la capacidad discriminativa a través de distintos umbrales y no reemplaza a las métricas de clase.

Modelo	Accuracy	Precision	Recall	F1-score	ROC-AUC
Regresión Logística	0,8092	0,7717	0,7100	0,7396	0,8680
Random Forest	0,7901	0,7273	0,7200	0,7236	0,8575
Red Neuronal	0,8397	0,8295	0,7300	0,7766	0,8711

La Red Neuronal obtiene el mejor resultado en todas las métricas del conjunto de prueba: accuracy 0,8397, precision 0,8295, recall 0,7300, F1-score 0,7766 y ROC-AUC 0,8711. La Regresión Logística presenta un desempeño competitivo y cercano en ROC-AUC (0,8680), mientras que Random Forest obtiene un recall de 0,7200, pero queda por debajo en accuracy, precision, F1-score y AUC. Por ello, la selección de la Red Neuronal se sustenta en el comportamiento conjunto de las métricas, no en una sola cifra.

Métrica	Valor	Interpretación técnica en el caso
Accuracy	0,8397	El 83,97 % de las 262 observaciones de prueba fue clasificado correctamente.
Precision	0,8295	De los casos predichos como sobrevivientes, el 82,95 % corresponde a sobrevivientes reales.
Recall	0,7300	El modelo detecta el 73,00 % de los 100 sobrevivientes reales del conjunto de prueba.
F1-score	0,7766	Resume un equilibrio favorable entre precision y recall, aunque el recall deja margen de mejora.
ROC-AUC	0,8711	Indica buena capacidad global para discriminar entre sobrevivientes y no sobrevivientes.




Figura 2. Comparación de métricas en el conjunto de prueba para los tres modelos ejecutados.

IV. Matriz de confusión y métricas de clasificación

La matriz de confusión del modelo final se calculó exclusivamente sobre las 262 observaciones del conjunto de prueba. Las filas representan la clase real y las columnas la clase predicha. Para la clase positiva sobrevivió (1), el notebook registra 147 verdaderos negativos, 15 falsos positivos, 27 falsos negativos y 73 verdaderos positivos.




Figura 3. Matriz de confusión de la Red Neuronal sobre el conjunto de prueba.

Componente	Cantidad	Lectura aplicada
Verdadero negativo (TN)	147	No sobrevivió y el modelo predijo no sobrevivió.
Falso positivo (FP)	15	No sobrevivió, pero el modelo predijo sobrevivió.
Falso negativo (FN)	27	Sobrevivió, pero el modelo predijo no sobrevivió.
Verdadero positivo (TP)	73	Sobrevivió y el modelo predijo sobrevivió.

Las métricas se verifican directamente desde la matriz: $\text{accuracy} = (147 + 73) / 262 = 0,8397$; $\text{precision} = 73 / (73 + 15) = 0,8295$; $\text{recall} = 73 / (73 + 27) = 0,7300$; y $\text{F1-score} = 0,7766$. La especificidad complementaria es $147 / (147 + 15) = 0,9074$. Esta consistencia confirma que los valores reportados por el notebook corresponden a la matriz observada.

Nota metodológica: El notebook utiliza predict() para convertir probabilidades en etiquetas. Para clasificación binaria de MLPClassifier, esto corresponde al criterio predeterminado de clase con mayor probabilidad; no se realizó optimización específica del umbral. El material de la Fase 4 señala que modificar el umbral cambia el equilibrio precision-recall, por lo que puede explorarse en una iteración posterior.

V. Interpretación del desempeño del modelo

La lectura del desempeño debe integrar métricas y tipos de error. El material docente enfatiza que modelos con accuracy similar pueden ser muy distintos si uno produce más falsas alarmas y otro omite más positivos (Ruete, 2026a). En la Red Neuronal, la alta especificidad (0,9074) muestra una buena capacidad para reconocer no sobrevivientes; en cambio, el recall de 0,7300 indica que existe una pérdida relevante de casos positivos.

Tipo	Evidencia	Interpretación
Fortaleza	Accuracy 0,8397	Buen desempeño global en el conjunto de prueba.
Fortaleza	Precision 0,8295	Las predicciones positivas presentan una tasa de acierto elevada.
Fortaleza	ROC-AUC 0,8711	Buena capacidad discriminativa global.
Limitación	27 falsos negativos	El 27 % de los sobrevivientes reales del test no fue identificado.
Limitación	Recall 0,7300	La sensibilidad es inferior a precision y especificidad.
Condición	Validación CV solo para la Red Neuronal	La estabilidad no puede compararse entre los tres modelos bajo el mismo protocolo CV.

La principal limitación aplicada son los falsos negativos. Si el problema priorizara detectar la mayor cantidad posible de casos positivos, el recall debería recibir mayor peso que accuracy. En cambio, si las falsas alarmas fueran costosas, la precision tendría mayor prioridad. Esta relación entre métrica y costo del error es central para interpretar clasificadores de forma contextualizada (Ruete, 2026a; James et al., 2021).

VI. Interpretación para toma de decisiones

El caso Titanic es pedagógico y no pretende sostener una decisión operativa contemporánea. Su valor analítico radica en demostrar cómo las métricas orientan decisiones distintas. Con la Red Neuronal, el 83,97 % de aciertos globales y el AUC de 0,8711 respaldan una clasificación útil, pero los 27 falsos negativos obligan a considerar el costo de no detectar parte de la clase positiva.

Criterio de decisión	Resultado más favorable	Implicancia
Priorizar desempeño global	Red Neuronal	Mayor accuracy y F1-score del test.
Priorizar confiabilidad de positivos	Red Neuronal	Mayor precision (0,8295) entre los tres modelos.
Priorizar detección de positivos	Red Neuronal	Mayor recall (0,7300), aunque aún omite 27 % de positivos del test.
Priorizar explicabilidad	Regresión Logística	Desempeño competitivo y coeficientes directamente interpretables.
Reducir riesgo de una sola partición	Validación cruzada	Usar el promedio y variabilidad de folds como evidencia complementaria.

La selección final del modelo se realiza a partir de dos evidencias: el desempeño Hold-Out y la validación cruzada. La Red Neuronal lidera las métricas del conjunto de prueba y, además, fue sometida a Stratified K-Fold. Sin embargo, la diferencia entre su accuracy de prueba (0,8397) y el promedio de validación cruzada (0,7899) muestra que una única partición puede resultar más favorable que el comportamiento promedio. En consecuencia, para tomar decisiones se debe comunicar tanto el rendimiento puntual como la incertidumbre asociada a las particiones.

VII. Notebook y trazabilidad del proceso de evaluación del modelo

El notebook MCDI504_S4_2_GRUPO6.ipynb contiene el flujo completo de evaluación: carga, exploración, selección de predictores, partición, imputación, codificación, escalamiento, entrenamiento de modelos, generación de probabilidades, cálculo de métricas, matrices de confusión, ROC-AUC, validación cruzada y selección final. La secuencia es auditable porque las salidas numéricas que se reportan en este informe aparecen ejecutadas en las celdas correspondientes.

Etapa	Evidencia de código	Resultado trazable
Carga	fetch_openml(name="titanic", version=1, as_frame=True)	1.309 x 14
Partición	train_test_split(..., test_size=0.20, stratify=y)	1.047 train / 262 test
Imputación	Medianas/moda calculadas solo en train	age=28,00; fare=13,81665; embarked=S
Codificación	pd.get_dummies(..., drop_first=True)	8 predictores finales
Escalamiento	StandardScaler fit en train	Variables numéricas estandarizadas
Evaluación	accuracy/precision/recall/F1/confusion_matrix/ROC-AUC	Tablas III-IV
Validación	StratifiedKFold(n_splits=5, shuffle=True, random_state=42)	Resultados de sección IX

Fragmentos clave del notebook

```
X_train, X_test, y_train, y_test = train_test_split(
    X_raw, y, test_size=0.20, random_state=42, stratify=y
)

red_neuronal = Pipeline([
    ('scaler', StandardScaler()),
    ('mlp', MLPClassifier(hidden_layer_sizes=(16,), activation='relu',
                          solver='adam', max_iter=1000, random_state=42))
])
```

Repositorio GitHub del proyecto: https://github.com/LUISKARESPINOZA/MCDI504_S4_GRUPO6. Para cumplir completamente C6, el repositorio debe contener la misma versión del notebook, este informe final, un README con dependencias e instrucciones de ejecución y, cuando corresponda, las figuras utilizadas. La correspondencia entre archivos debe mantenerse sin resultados contradictorios.

Nota metodológica: Durante la auditoría se detectó que una celda narrativa del notebook conservaba valores antiguos de validación cruzada y otra síntesis presentaba AUC=0,8593 para Random Forest. En la versión revisada del notebook se corrigen esas narrativas para que coincidan con las salidas ejecutadas: CV accuracy 0,7899 ± 0,0134 y AUC de Random Forest 0,8575.

VIII. Conclusiones técnicas del desempeño del modelo

La evaluación Hold-Out muestra que la Red Neuronal es el clasificador con mejor desempeño del conjunto analizado. En las 262 observaciones de prueba obtuvo accuracy 0,8397, precision 0,8295, recall 0,7300, F1-score 0,7766 y ROC-AUC 0,8711. La matriz de confusión confirma 220 aciertos y 42 errores: 15 falsos positivos y 27 falsos negativos.

El modelo presenta una fortaleza clara en discriminación general y control de falsos positivos, pero la detección de la clase positiva sigue siendo el principal punto de mejora. Una futura iteración debería estudiar el umbral de decisión, hiperparámetros del MLP, regularización y eventualmente curvas precision-recall, preservando un conjunto de prueba independiente. También es recomendable comparar los tres modelos bajo el mismo esquema de validación si se pretende fundamentar diferencias de estabilidad y no solo de desempeño Hold-Out.

IX. Reporte tabulado e interpretación de estabilidad de métricas

La Red Neuronal fue validada mediante Stratified K-Fold con cinco particiones sobre las 1.047 observaciones del conjunto de entrenamiento. La estratificación mantiene aproximadamente la proporción 61,8 % / 38,2 % de las clases en cada fold. K-Fold permite observar la variabilidad entre particiones y entrega una estimación menos dependiente de una sola división que Hold-Out (Ruete, 2026b).

Fold	Accuracy	Precision	Recall	F1-score	AUC
1	0,7905	0,7500	0,6750	0,7105	0,8401
2	0,7810	0,7833	0,5875	0,6714	0,8541
3	0,8086	0,7439	0,7625	0,7531	0,8630
4	0,7990	0,8393	0,5875	0,6912	0,8295
5	0,7703	0,8077	0,5250	0,6364	0,8660

Métrica	Media	Desv. estándar	Lectura de estabilidad
Accuracy	0,7899	0,0134	Baja variabilidad relativa
Precision	0,7848	0,0357	Variabilidad moderada
Recall	0,6275	0,0827	Mayor variabilidad; principal alerta
F1-score	0,6925	0,0390	Variabilidad moderada
ROC-AUC	0,8506	0,0139	Baja variabilidad relativa




Figura 4. Desempeño por fold y variabilidad de la validación cruzada de la Red Neuronal.

Accuracy y ROC-AUC son las métricas más estables, con desviaciones estándar cercanas a 0,014. Recall es la más sensible a la partición: varía entre 0,5250 y 0,7625, un rango de 0,2375. Además, el accuracy Hold-Out supera en 0,0498 al promedio de validación cruzada y el recall Hold-Out supera en 0,1025 al recall medio de los folds. Por tanto, la partición de prueba utilizada entrega una lectura más favorable que el desempeño promedio interno, especialmente para la detección de positivos.

X. Justificación de técnica de validación

La técnica seleccionada es Stratified K-Fold Cross-Validation con $k=5$. La elección se justifica por el tamaño moderado del conjunto de entrenamiento (1.047 observaciones), el costo de entrenar una red MLP y la necesidad de estimar estabilidad. El material docente indica que K-Fold suele ofrecer un compromiso equilibrado entre robustez de la estimación y costo computacional, mientras que Hold-Out es más barato pero depende de una sola partición y Leave-One-Out puede resultar impracticable cuando el número de observaciones crece (Ruete, 2026b).

Técnica	Entrenamientos	Costo	Estabilidad esperada	Decisión
Hold-Out	1 entrenamiento	Bajo	Menor; depende de una sola partición	Se mantiene como prueba final independiente.
Stratified K-Fold ($k=5$)	5 entrenamientos	Medio	Mayor; permite media y dispersión	Técnica principal para analizar estabilidad del MLP.
Leave-One-Out	≈ 1.047 entrenamientos	Alto	Uso intensivo de datos, costo elevado	No se justifica para esta red y tamaño de entrenamiento.

La estratificación añade coherencia porque la clase sobrevivió representa aproximadamente el 38,2 % de la muestra. Cada fold conserva una proporción similar de positivos y negativos, reduciendo el riesgo de que diferencias de composición de clase dominen las métricas. La elección de cinco folds está también alineada con el material de la sesión, donde $k=5$ o $k=10$ se presenta como una opción frecuente para equilibrar estabilidad y costo (Universidad Andrés Bello, 2026).

XI. Coherencia metodológica de validación

La metodología es coherente en varios aspectos: el problema es binario; la clase positiva está explícitamente definida; las métricas corresponden al objetivo; la partición Hold-Out es estratificada; la Red Neuronal se evalúa con Stratified K-Fold; y se reportan media y desviación estándar para analizar estabilidad. Además, el test final no participa en la validación cruzada.

Dimensión	Decisión aplicada	Coherencia con la evaluación
Tipo de problema	Clasificación binaria	Justifica matriz de confusión y métricas de clasificación.
Clase positiva	survived=1	Define la interpretación de precision, recall y F1.
Hold-Out	20 % test estratificado	Permite evaluación final sobre datos no usados para entrenar.
Validación interna	Stratified K-Fold k=5	Mantiene proporciones de clase y permite estimar variabilidad.
Modelo validado	MLP 8 -> 16 -> salida binaria	Cumple el análisis de una red neuronal superficial.
Evidencia	Media y desviación por métrica	Permite interpretar estabilidad, no solo desempeño puntual.

Nota metodológica: Existe una limitación metodológica relevante: la imputación, la codificación y un primer escalamiento se ejecutan sobre todo `X_train` antes de `cross_validate`. Por ello, parte del preprocesamiento que aprende parámetros ya fue estimado con observaciones que luego actúan como validación interna. El material docente establece que estas transformaciones deben aprenderse dentro de cada fold para evitar data leakage. El conjunto de prueba externo sigue siendo independiente, pero las métricas de CV podrían ser ligeramente optimistas. La mejora recomendada es encapsular imputación, OneHotEncoder, StandardScaler y MLP en un único Pipeline/ColumnTransformer alimentado con los datos crudos de entrenamiento.

Esta observación no invalida la trazabilidad de los valores registrados, pero sí delimita su interpretación. El informe conserva los resultados efectivamente ejecutados y declara la precaución en lugar de presentar la validación interna como completamente libre de filtración. Esta transparencia es consistente con el propósito de la fase: construir evidencia reproducible y reconocer condiciones que afectan la generalización.

XII. Notebook y trazabilidad del proceso de validación

El bloque de validación define StratifiedKFold, configura cinco particiones con shuffle=True y random_state=42 y utiliza cross_validate para obtener accuracy, precision, recall, F1-score y ROC-AUC en cada fold. La salida del notebook incluye tanto la tabla por fold como el resumen de media y desviación estándar, por lo que los valores de la sección IX pueden rastrearse directamente al código.

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

scoring = {
    'accuracy': 'accuracy',
    'precision': make_scorer(precision_score, pos_label=1, zero_division=0),
    'recall': make_scorer(recall_score, pos_label=1, zero_division=0),
    'f1': make_scorer(f1_score, pos_label=1, zero_division=0),
    'roc_auc': 'roc_auc'
}

cv_resultados = cross_validate(
    red_neuronal, X_train, y_train.astype(int), cv=cv, scoring=scoring
)
```

Evidencia de validación	Resultado ejecutado
Número de folds	5
Semilla	random_state=42
Accuracy medio	0,7899
Desv. estándar accuracy	0,0134
Recall medio	0,6275
Desv. estándar recall	0,0827
AUC medio	0,8506
Desv. estándar AUC	0,0139

La versión revisada del notebook adjunta conserva el código y las salidas ejecutadas, corrige únicamente las narrativas que contenían valores antiguos y documenta la precaución metodológica del preprocesamiento previo a los folds. Repositorio GitHub: https://github.com/LUISKARESPINOZA/MCDI504_S4_GRUPO6.

XIII. Conclusiones técnicas del proceso de validación

Stratified K-Fold con cinco particiones permitió complementar el resultado Hold-Out con una estimación de estabilidad sobre múltiples subconjuntos del entrenamiento. El promedio de accuracy fue $0,7899 \pm 0,0134$ y el de ROC-AUC $0,8506 \pm 0,0139$, lo que muestra una dispersión reducida en ambas métricas. F1-score alcanzó $0,6925 \pm 0,0390$. En contraste, recall fue $0,6275 \pm 0,0827$ y exhibió la mayor variabilidad entre folds.

La técnica es pertinente para un conjunto de entrenamiento de 1.047 registros porque utiliza los datos de forma eficiente y requiere solo cinco entrenamientos, frente a aproximadamente 1.047 en Leave-One-Out. Sin embargo, la diferencia entre el test final y el promedio de CV obliga a interpretar el 0,8397 de accuracy del test con cautela. El modelo tiene buen desempeño, pero la evidencia de generalización es más conservadora.

Como mejora metodológica prioritaria, el preprocesamiento completo debe trasladarse al interior de cada fold mediante Pipeline/ColumnTransformer. Después de esa corrección, conviene repetir la validación, estudiar hiperparámetros y analizar el umbral de decisión si el objetivo aplicado asigna mayor costo a los falsos negativos. También sería metodológicamente más sólido validar Regresión Logística y Random Forest con los mismos folds si se desea comparar estabilidad entre algoritmos.

XIV. Uso de fuentes, citación y referencias

El informe integra material docente, documentación técnica oficial y bibliografía académica. Las fuentes docentes sustentan la lectura de métricas y la selección de la técnica de validación; la documentación oficial respalda la implementación de StratifiedKFold, MLPClassifier y Pipeline; y la bibliografía académica complementa la discusión sobre generalización y evaluación de modelos.

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). An introduction to statistical learning: With applications in R (2nd ed.). Springer.

Ruete, D. (2026a). Métricas de evaluación: accuracy, F1-score, curva ROC-AUC, curvas precisión-recall, matriz de confusión [Apunte de curso]. Universidad Andrés Bello.

Ruete, D. (2026b). Técnicas de evaluación: validación cruzada (K-Fold Cross-Validation, Leave-One-Out Validation, Hold-Out Validation) [Apunte de curso]. Universidad Andrés Bello.

Universidad Andrés Bello. (2026). Fase 4: métricas y técnicas de evaluación. Evaluación rigurosa de clasificadores y generalización [Presentación de apoyo, MCDI504 Machine Learning I].

scikit-learn Developers. (s. f.-a). MLPClassifier. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.neural_network.MLPClassifier.html

scikit-learn Developers. (s. f.-b). StratifiedKFold. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html

scikit-learn Developers. (s. f.-c). Pipeline. Scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.pipeline.Pipeline.html>

scikit-learn Developers. (s. f.-d). Metrics and scoring: Quantifying the quality of predictions. Scikit-learn documentation. https://scikit-learn.org/stable/modules/model_evaluation.html

XV. Anexos

Anexo A. Resultados completos de los modelos

Modelo	TN	FP	FN	TP	Acc.	Prec.	Rec.	F1	AUC
Regresión Logística	141	21	29	71	0,8092	0,7717	0,7100	0,7396	0,8680
Random Forest	135	27	28	72	0,7901	0,7273	0,7200	0,7236	0,8575
Red Neuronal	147	15	27	73	0,8397	0,8295	0,7300	0,7766	0,8711

Anexo B. Evidencia complementaria del notebook




Figura A1. Curvas ROC comparativas de Regresión Logística y Random Forest generadas en el notebook.




Figura A2. Importancia de variables estimada por Random Forest.